

Segmentarea instantelor pentru detectarea deseurilor folosind Mask R-CNN si un cap auxiliar multi-label

Vasile Breban

May 20, 2026

Acest proiect studiaza segmentarea instantelor pe setul de date TACO Trash Segmentation. Este utilizat un model Mask R-CNN cu backbone ResNet-50 FPN, ajustat pentru cele mai frecvente zece clase de deseuri. In plus, este adaugat un cap auxiliar de clasificare multi-label la nivel de imagine, folosit ca al doilea task de invatare. Evaluarea finala compara un model pretrained adaptat, modelul Mask R-CNN fine-tuned si modelul multi-task, folosind metrici pentru detectie si segmentare. Fine-tuning-ul imbunatateste performanta fata de baseline, iar capul auxiliar creste recall-ul si scorul F1 la pragul IoU 0.50.

1 Introducere

Detectarea deseurilor este o problema utila de viziune artificiala pentru reciclare, monitorizare urbana si analiza mediului. Obiectivul acestui proiect este detectarea obiectelor de tip deșeu in imagini reale, localizarea lor prin bounding box-uri si segmentarea fiecărei instante folosind o masca binara. Task-ul ales este segmentarea instantelor, deoarece fiecare obiect vizibil trebuie reprezentat separat.

Contributia proiectului consta intr-un flux complet de deep learning: analiza setului de date, curatarea datelor, preprocesare, augmentare, fine-tuning, invatare multi-head, evaluare si vizualizare calitativa. Modelul principal este Mask R-CNN cu backbone ResNet-50 FPN. Pe langa capetele standard de detectie si masca, este adaugat un cap auxiliar de clasificare multi-label la nivel de imagine, care prezice clasele de deseuri prezente in imagine.

2 Lucrari relationate

Mask R-CNN extinde Faster R-CNN prin adaugarea unei ramuri pentru masti si ramane un baseline puternic pentru segmentarea instantelor [1]. ResNet introduce conexiuni reziduale care permit optimizarea mai usoara a retelelor CNN adanci [2]. COCO a stabilit protocoale standard de evaluare pentru detectia si segmentarea obiectelor, inclusiv AP si AP50 [3]. Setul de date TACO ofera adnotari pentru deseuri in contexte naturale si este potrivit pentru experimente de detectare a litter-ului [4]. Albumentations este folosit pentru transformari sigure asupra imaginilor si adnotarilor [5].

3 Metodologie

Setul de date folosit este TACO Trash Segmentation in format COCO. Impartirea initiala contine 1504 imagini si 4819 adnotari. Spatiul initial de etichete are 61 de categorii COCO, insa multe clase au foarte putine instante. Pentru a face antrenarea fezabila pe un GPU Google Colab T4, sunt pastrate cele mai reprezentate zece clase foreground, dupa aplicarea unui criteriu de numar minim de instante.

Dupa filtrare, setul de date contine 1123 imagini si 3185 adnotari. Impartirile train, validation si test contin 782, 225 si respectiv 116 imagini. Clasele pastrate sunt Cigarette, Unlabeled litter, Plastic film, Clear plastic bottle, Other plastic, Other plastic wrapper, Drink can, Plastic bottle cap, Plastic straw si Broken glass. Aceasta selectie pastreaza 66.09% din adnotari si reduce spatiul de clasificare la o configuratie mai stabila pentru resurse de calcul limitate.




Figure 1: Distributia finala a claselor selectate dupa filtrare.

Pipeline-ul de preprocesare citeste imaginile RGB, remapeaza etichetele la identificatori consecutivi, converteste bounding box-urile COCO in formatul asteptat de Mask R-CNN si creeaza masti binare pentru fiecare instanta. Imaginile sunt redimensionate pastrand raportul de aspect folosind `LongestMaxSize`, apoi sunt completate prin padding pana la dimensiunea 512 x 512 pixeli. Aceasta abordare evita distorsiunile geometrice si mentine utilizarea memoriei predictibila.

Augmentarile folosite la antrenare includ flip orizontal, modificari de luminozitate si contrast, precum si transformari affine de tip shift-scale-rotate. Aceste augmentari sunt relevante deoarece obiectele de tip deseu pot aparea in pozitii, conditii de iluminare si orientari diferite. Albumentations este utilizat pentru ca imaginile, bounding box-urile si mastile sa fie transformate consistent.

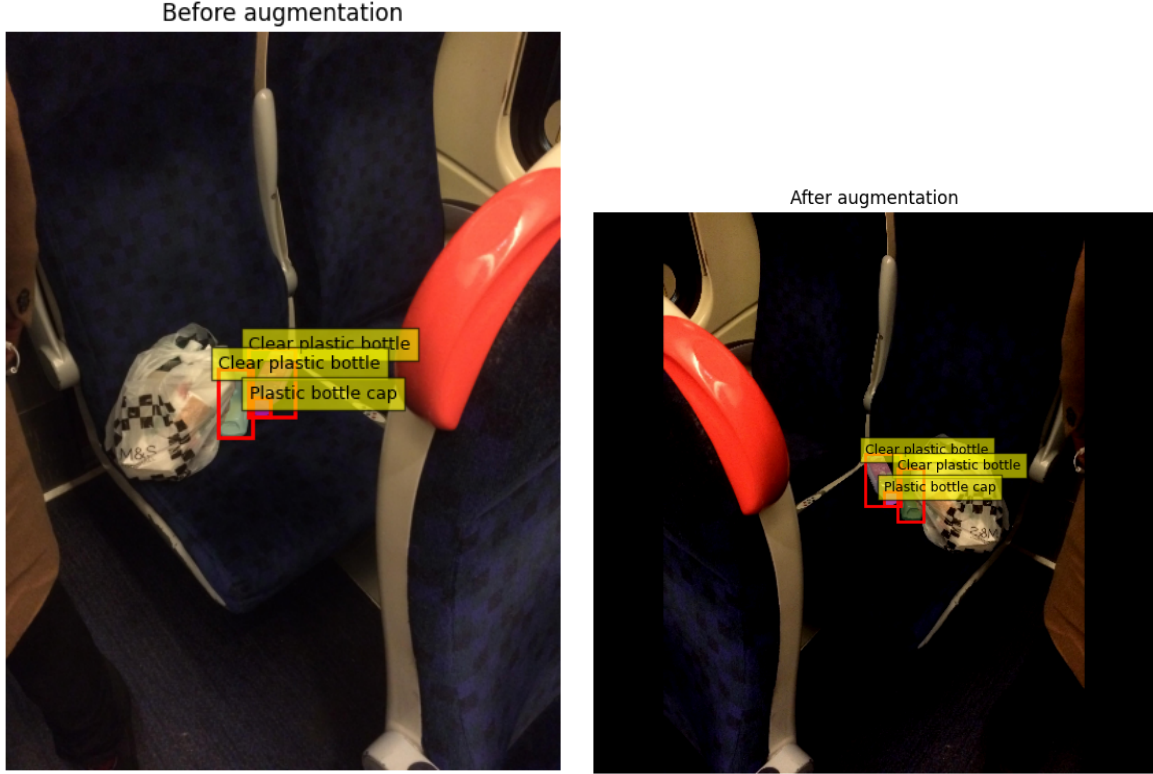


Figure 2: Exemplu de augmentare sigura pentru adnotari, inainte si dupa transformare.

Arhitectura principala este Mask R-CNN cu backbone ResNet-50 FPN initializat cu ponderi pretrained. Predictorul pentru bounding box-uri si predictorul pentru masti sunt inlocuite pentru a corespunde celor zece clase selectate plus clasa background. Fine-tuning-ul este realizat in doua etape. Mai intai, backbone-ul este inghetat si sunt adaptate doar capetele de task. Apoi, backbone-ul este dezghetat si antrenat cu o rata de invatare mai mica.

Capul aditional este un clasificator multi-label la nivel de imagine. Acesta primeste trasaturi agregate din backbone si prezice clasele prezente in imagine. Functia sa de pierdere este binary cross-entropy with logits. In timpul antrenarii, pierderea totala este:

$$L = L_{maskrcnn} + \lambda L_{aux}, \quad (1)$$

unde $L_{maskrcnn}$ este suma pierderilor standard Mask R-CNN, iar $\lambda = 0.2$ controleaza importanta pierderii auxiliare de clasificare.

4 Experimente

Baseline-ul este un model Mask R-CNN pretrained adaptat, ale carui capete finale sunt inlocuite, dar care nu este fine-tuned. Al doilea model este Mask R-CNN fine-tuned. Al treilea model este versiunea multi-task cu un cap auxiliar. Evaluarea este realizata pe split-ul de test curatat, care contine 116 imagini.

Table 1: Metricile principale pe test la IoU 0.50.

Model	Precision	Recall	F1	Mask IoU
Baseline pretrained adaptat	0.000	0.000	0.000	0.000
Mask R-CNN fine-tuned	0.425	0.124	0.191	0.830
Mask R-CNN + cap auxiliar	0.353	0.168	0.227	0.811

Fine-tuning-ul imbunatateste clar baseline-ul. Modelul pretrained adaptat nu produce true positives la pragul de scor selectat. Modelul fine-tuned ajunge la un scor F1 de 0.191 la IoU 0.50 si obtine cel mai bun Mask IoU pentru mastile potrivite. Capul auxiliar creste recall-ul si scorul F1, dar produce si mai multe false positives, ceea ce reduce precizia. Acest rezultat arata ca head-ul auxiliar ajuta modelul sa recupereze mai multe obiecte, dar nu imbunatateste uniform toate metricile.

Table 2: Rezumatul pierderilor de antrenare.

Etapă	Train loss	Validation loss
Fine-tuning epoca 1	0.984	0.823
Fine-tuning epoca 5	0.634	0.709
Auxiliar epoca 1	0.764	0.824
Auxiliar epoca 2	0.703	0.781

Pierdere de validare pentru modelul fine-tuned scade de la 0.823 in prima epoca la 0.709 dupa cinci epoci, ceea ce indica o invatare stabila. Modelul auxiliar isi reduce de asemenea pierdere totala de validare de la 0.824 la 0.781 in cele doua epoci auxiliare. Componenta finala a pierderii auxiliare de validare este aproximativ 0.086, ceea ce arata ca clasificatorul la nivel de imagine primeste un semnal invatabil.




Figure 3: Curbele de train loss si validation loss pentru modelul fine-tuned si modelul multi-task.

5 Concluzii

Proiectul implementeaza un pipeline complet de segmentare a instantelor pe un set de date real. Modelul Mask R-CNN fine-tuned invata subsetul TACO selectat si imbunatateste

substantial performanta fata de baseline-ul pretrained adaptat. Capul auxiliar multi-label modifica comportamentul modelului prin cresterea recall-ului si a scorului F1 la IoU 0.50, desi acest lucru vine cu un cost: mai multe false positives si o precizie mai mica.

Principalele limitari sunt dezechilibrul dintre clase, numarul redus de epoci de antrenare si subsetul redus de clase folosit pentru fezabilitate pe Colab T4. Ca directii viitoare, ar trebui raportat COCO AP complet pe fiecare clasa, folosita esantionarea constienta de clase, ajustat pragul de scor si comparat modelul cu o alta arhitectura, precum YOLO segmentation sau un model de tip DETR.

References

- [1] K. He, G. Gkioxari, P. Dollar, and R. Girshick, "Mask r-cnn," in *Proceedings of the IEEE International Conference on Computer Vision*, 2017.
- [2] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2016.
- [3] T.-Y. Lin, M. Maire, S. Belongie, J. Hays, P. Perona, D. Ramanan, P. Dollar, and C. L. Zitnick, "Microsoft coco: Common objects in context," in *European Conference on Computer Vision*, 2014.
- [4] P. F. Proenca and P. Simoes, "Taco: Trash annotations in context for litter detection," *arXiv preprint arXiv:2003.06975*, 2020.
- [5] A. Buslaev, V. I. Iglovikov, E. Khvedchenya, A. Parinov, M. Druzhinin, and A. A. Kalinin, "Albumentations: Fast and flexible image augmentations," *Information*, vol. 11, no. 2, p. 125, 2020.